

1 Wstęp

1.1 Nieliniowe zadanie najmniejszych kwadratów z więzami

Nieliniowe zadanie najmniejszych kwadratów z więzami ma postać

$$\begin{aligned} & \underset{x}{\text{minimize}} && \|f(x)\|^2 \\ & \text{subject to} && g(x) = 0 \end{aligned} \quad (1)$$

gdzie $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$, są różniczkowalnymi funkcjami wektorowymi

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{bmatrix}, \quad g(x) = \begin{bmatrix} g_1(x) \\ \vdots \\ g_p(x) \end{bmatrix}. \quad (2)$$

Zadanie (1) możemy sformułować inaczej jako

$$\begin{aligned} & \underset{x}{\text{minimize}} && f_1(x)^2 + \dots + f_m(x)^2, \\ & \text{subject to} && g_1(x) = 0 \\ & && \vdots \\ & && g_p(x) = 0 \end{aligned} \quad (3)$$

Punkt $x \in \mathbb{R}^n$ nazywamy *dopuszczalnym* (ang. *feasible*) dla zadania (1) jeżeli spełnia równanie

$$g(x) = 0. \quad (4)$$

Punkt $x^* \in \mathbb{R}^n$ nazywamy rozwiązaniem zadania (1) jeżeli jest dopuszczalny i daje najmniejszą wartość funkcji celu spośród wszystkich punktów dopuszczalnych, tzn. $g(x^*) = 0$ oraz

$$g(x) = 0 \implies \left(\|f(x^*)\|^2 \leq \|f(x)\|^2 \right). \quad (5)$$

Przypomnijmy, że nieliniowe zadanie najmniejszych kwadratów **bez więzów**, czyli zadanie optymalizacji postaci

$$\underset{x \in \mathbb{R}^n}{\text{minimize}} \quad \|f(x)\|^2, \quad (6)$$

gdzie $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{bmatrix} \quad (7)$$

jest zadaną (różniczkowalną) funkcją, można rozwiązywać za pomocą algorytmu Levenberga-Marquardta [1]. Metody tej nie można bezpośrednio zastosować do zadań typu (1), czyli z więzami, jednak stanowi ona ważny składnik omówionych w dalszej części algorytmów, odpowiednio, kary i rozszerzonego lagranżjanu, za pomocą których można rozwiązywać zadania z więzami.

1.2 Algorytm kary (ang. *penalty algorithm*)

Zadanie (1) możemy traktować jako przypadek graniczny zadania

$$\underset{x \in \mathbb{R}^n}{\text{minimize}} \quad \|f(x)\|^2 + \mu \|g(x)\|^2, \quad (8)$$

dla dużych wartości parametru $\mu > 0$. Wyraz $\mu \|g(x)\|^2$ nazywamy składnikiem kary (ang. *penalty term*). Zauważmy, że

$$\|f(x)\|^2 + \mu \|g(x)\|^2 = \left\| \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) \end{bmatrix} \right\|^2 \quad (9)$$

zatem dla ustalonej wartości parametru μ zadanie (8) można rozwiązać metodą Levenberga-Marquardta. Dla dużych wartości μ powinniśmy otrzymać minimalizator x_μ^* dla którego $\|f(x_\mu^*)\|^2$ jest możliwie małe, zaś $\|g(x_\mu^*)\|^2$ bardzo małe, $\|g(x_\mu^*)\|^2 \approx 0$, czyli $g(x_\mu^*) \approx 0$. Oznacza to, że dla odpowiednio dużej wartości parametru μ , rozwiązanie zadania (8), które oznaczamy x_μ^* , jest przybliżonym rozwiązaniem zadania (1). Posumowując, algorytm kary dla nieliniowego zadania LS z więzami (ang. *penalty algorithm for constraint nonlinear least squares*) jest następujący.

Dane: $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$, punkt startowy $x^{(0)}$, maksymalna liczba iteracji k_{\max} , $\mu^{(0)} = 1$. Dla $k = 0, 1, \dots, k_{\max}$. Dla $k = 0, 1, \dots, k_{\max}$

1. Metodą LM, przyjmując punkt startowy $x^{(k)}$, $\mu^{(k)}$ znajdź rozwiązanie x_μ^* zadania

$$\underset{x \in \mathbb{R}^n}{\text{minimize}} \quad \|\tilde{f}(x)\|^2, \quad (10)$$

gdzie

$$\tilde{f}(x) = \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) \end{bmatrix}, \quad (11)$$

a następnie podstaw

$$x^{(k+1)} = x_\mu^*. \quad (12)$$

2. Wykonaj aktualizację

$$\mu^{(k+1)} = 2\mu^{(k)}. \quad (13)$$

Teoretycznie można by od razu wziąć odpowiednio dużą wartość parametru μ , jednak prowadziłyby to do trudności numerycznych, dlatego parametr ten lepiej zwiększać stopniowo w kolejnych iteracjach. W praktyce nawet przy takim ostrożnym podejściu algorytm kary nie zawsze jest skuteczny, dlatego częściej stosuje się tzw. algorytm rozszerzonego lagranżjanu (ang. *augmented Lagrangian algorithm, ALA*) [1, 2].

1.3 Algorytm rozszerzonego lagranżjanu

Lagranżjan dla zadania (1) jest postaci

$$\begin{aligned} L(x, z) &= \|f(x)\|^2 + \sum_{i=1}^p z_i g_i(x) \\ &= \|f(x)\|^2 + z^T g(x), \end{aligned} \quad (14)$$

gdzie $z \in \mathbb{R}^p$ jest wektorem mnożników Lagrange'a. Na mocy twierdzenia Lagrange'a wiadomo, że warunkiem koniecznym optymalności dla zadania (1) jest zerowanie się gradientu lagranżjanu, tzn. $\nabla L(x, z) = 0$. Mamy

$$\nabla L(x, z) = \begin{bmatrix} \nabla_x L(x, z) \\ \nabla_z L(x, z) \end{bmatrix} = 0, \quad (15)$$

Mamy

$$\begin{aligned}
\nabla \|f(x)\|_2^2 &= \nabla \left(\sum_{i=1}^N f_i(x)^2 \right) \\
&= \sum_{i=1}^N \nabla (f_i(x)^2) \\
&= \sum_{i=1}^N 2f_i(x) \nabla f_i(x) \\
&= 2[Df(x)]^T f(x),
\end{aligned} \tag{16}$$

oraz

$$\begin{aligned}
\nabla(z^T g(x)) &= \nabla \left(\sum_{i=1}^p z_i g_i(x) \right) \\
&= \sum_{i=1}^p z_i \nabla g_i(x) \\
&= [\nabla g_1(x) \quad \dots \quad \nabla g_p(x)] \begin{bmatrix} z_1 \\ \vdots \\ z_p \end{bmatrix} \\
&= [Dg(x)]^T z,
\end{aligned} \tag{17}$$

zatem, uwzględniając (14), z warunku (15) otrzymujemy

$$\begin{aligned}
\nabla L(x, z) &= \begin{bmatrix} \nabla_x L(x, z) \\ \nabla_z L(x, z) \end{bmatrix} \\
&= \begin{bmatrix} \nabla_x (\|f(x)\|^2 + z^T g(x)) \\ \nabla_z (\|f(x)\|^2 + z^T g(x)) \end{bmatrix} \\
&= \begin{bmatrix} 2[Df(x)]^T f(x) + [Dg(x)]^T z \\ g(x) \end{bmatrix} \\
&= 0,
\end{aligned} \tag{18}$$

czyli

$$2[Df(x)]^T f(x) + [Dg(x)]^T z = 0, \tag{19a}$$

$$g(x) = 0. \tag{19b}$$

Każde rozwiązanie zadania (1) musi spełniać równania (19). Tzw. rozszerzony lagranżjan (ang. *augmented Lagrangian*) dla zadania (1) definiujemy następująco

$$\begin{aligned}
L_\mu(x, z) &= L(x, z) + \mu \|g(x)\|^2 \\
&= \|f(x)\|^2 + z^T g(x) + \mu \|g(x)\|^2,
\end{aligned} \tag{20}$$

i jest „zwykłym” lagranżjanem dla zadania

$$\text{minimize}_x \quad \|f(x)\|^2 + \mu \|g(x)\|^2, \tag{21}$$

$$\text{subject to} \quad g(x) = 0, \tag{22}$$

które jest równoważne zadaniu (1) Zauważmy, że

$$\begin{aligned}
\mu \left\| g(x) + \frac{1}{2\mu} z \right\|^2 &= \mu \left[g(x) + \frac{1}{2\mu} z \right]^T \left[g(x) + \frac{1}{2\mu} z \right] \\
&= \mu \|g(x)\|^2 + 2\mu [g(x)]^T \left(\frac{1}{2\mu} z \right) + \mu \left\| \frac{1}{2\mu} z \right\|^2 \\
&= \mu \|g(x)\|^2 + [g(x)]^T z + \mu \left\| \frac{1}{2\mu} z \right\|^2
\end{aligned} \tag{23}$$

zatem

$$[g(x)]^T z + \mu \|g(x)\|^2 = \mu \left\| g(x) + \frac{1}{2\mu} z \right\|^2 - \mu \left\| \frac{1}{2\mu} z \right\|^2, \tag{24}$$

zatem

$$\begin{aligned}
L_\mu(x, z) &= \|f(x)\|^2 + [g(x)]^T z + \mu \|g(x)\|^2, \\
&= \|f(x)\|^2 + \mu \left\| g(x) + \frac{1}{2\mu} z \right\|^2 - \mu \left\| \frac{1}{2\mu} z \right\|^2
\end{aligned} \tag{25}$$

W metodzie ALA minimalizujemy względem x , używając algorytmu LM, rozszerzony lagranżjan (20) dla ciągu wartości $(\mu^{(k)}, z^{(k)})$, $k = 0, 1, \dots$. Ponieważ wyrażenie

$$\mu \left\| \frac{1}{2\mu} z \right\|^2 \tag{26}$$

nie zależy od x , to de facto minimalizujemy

$$\|f(x)\|^2 + \mu \left\| g(x) + \frac{1}{2\mu} z \right\|^2 \tag{27}$$

czyli

$$\left\| \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) + \frac{1}{2\sqrt{\mu}} z \end{bmatrix} \right\|^2. \tag{28}$$

Dowolny minimalizator \tilde{x} wyrażenia (27), musi spełniać warunek optymalności

$$\begin{aligned}
0 &= 2[Df(\tilde{x})]^T f(\tilde{x}) + 2\mu [Dg(\tilde{x})]^T \left(g(\tilde{x}) + \frac{1}{2\mu} z \right) \\
&= 2[Df(\tilde{x})]^T f(\tilde{x}) + [Dg(\tilde{x})]^T (2\mu g(\tilde{x}) + z).
\end{aligned} \tag{29}$$

Innymi słowy, po zminimalizowaniu (względem x) metodą LM wyrażenia (27) mamy minimalizator \tilde{x} , który spełnia równanie

$$2[Df(\tilde{x})]^T f(\tilde{x}) + [Dg(\tilde{x})]^T (2\mu g(\tilde{x}) + z) = 0. \tag{30}$$

Chcielibyśmy, aby były spełnione zależności

$$2[Df(\tilde{x})]^T f(\tilde{x}) + [Dg(\tilde{x})]^T z = 0, \tag{31a}$$

$$g(\tilde{x}) = 0. \tag{31b}$$

Żeby zachodziła równość (31a) wystarczy przyjąć

$$\tilde{z} = 2\mu g(\tilde{x}) + z. \tag{32}$$

Bardzo się ciesząc z tego sprytnego posunięcia, musimy pamiętać, że wciąż trzeba „coś zrobić” z równością (31b), która w ogólnym przypadku nie jest spełniona. Dlatego dla nowej wartości \tilde{z} ponownie minimalizujemy rozszerzony lagranżjan względem x .

Posumowując, algorytm ALA dla nieliniowego zadania LS z więzami (ang. *penalty algorithm for constraint nonlinear least squares*) jest następujący.

Dane: $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$, punkt startowy $x^{(0)}$, maksymalna liczba iteracji k_{\max} , $\mu^{(0)} = 1$, $z^{(1)} = \mathbf{1}$.

Dla $k = 0, 1, \dots, k_{\max}$:

1. Metodą LM, przyjmując punkt startowy $x^{(k)}$ znajdź rozwiązanie x_μ^* zadania

$$\text{minimize}_{x \in \mathbb{R}^n} \quad \|f(x)\|^2 + \mu^{(k)} \left\| g(x) + \frac{1}{2\mu^{(k)}} z^{(k)} \right\|^2, \tag{33}$$

Podstaw

$$x^{(k+1)} = x_\mu^*. \tag{34}$$

2. Wykonaj aktualizację

$$z^{(k+1)} = z^{(k)} + 2\mu^{(k)} g(x^{(k+1)}) \tag{35}$$

oraz

$$\mu^{(k+1)} = \begin{cases} \mu^{(k)} & \text{jeśli } \|g(x^{(k+1)})\| < 0.25 \|g(x^{(k+1)})\| \\ 2\mu^{(k)} & \text{jeśli } \|g(x^{(k+1)})\| \geq 0.25 \|g(x^{(k+1)})\| \end{cases}$$

Zauważmy, że punkt pierwszy sprowadza się do minimalizacji (względem x) metodą LM wyrażenia

$$\left\| \left[\sqrt{\mu^{(k)}} g(x) + \frac{1}{2\sqrt{\mu^{(k)}}} z^{(k)} \right] \right\|^2, \quad (36)$$

Algorytm ALA nie jest bardziej skomplikowany niż algorytm kary, jednak w praktyce działa znacznie lepiej, głównie z powodu wolniejszego wzrostu wartości parametru $\mu^{(k)}$ w miarę wzrostu indeksu k .

Przykład 1. [1] Stosując metodę ALA rozwiązać zadanie

$$\underset{x}{\text{minimize}} \quad \|f(x)\|^2, \quad (37a)$$

$$\text{subject to} \quad g(x) = 0, \quad (37b)$$

gdzie

$$f(x) = \begin{bmatrix} x_1 + \exp(-x_2) \\ x_1^2 + 2x_2 + 1 \end{bmatrix}, \quad (38a)$$

$$g(x) = x_1 + x_1^3 + x_2 + x_2^2. \quad (38b)$$

Przyjmując punkt startowy

$$x^{(0)} = \begin{bmatrix} 0.5000 \\ -0.5000 \end{bmatrix}, \quad (39)$$


otrzymujemy

$$x^{(1)} = \begin{bmatrix} -0.2730 \\ -0.1866 \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} -0.0993 \\ -0.0747 \end{bmatrix},$$

$$x^{(3)} = \begin{bmatrix} -0.0232 \\ -0.0183 \end{bmatrix}, \quad x^{(4)} = \begin{bmatrix} -0.0054 \\ -0.0043 \end{bmatrix},$$

$$x^{(5)} = \begin{bmatrix} -0.0013 \\ -0.0010 \end{bmatrix}, \quad x^{(6)} = \begin{bmatrix} -0.0003 \\ -0.0002 \end{bmatrix},$$

$$x^{(7)} = \begin{bmatrix} -0.0001 \\ -0.0001 \end{bmatrix}, \quad x^{(8)} = \begin{bmatrix} -0.0000 \\ -0.0000 \end{bmatrix}$$



Rysunek 1: Krzywa czerwona to zerowa poziomicza funkcji g , natomiast krzywe czarne są poziomiczami funkcji $\|f\|^2$. Niebieskie kropki oznaczają kolejne punkty iteracji. (Przykład 1)

Przypomnijmy warunki optymalności (19)

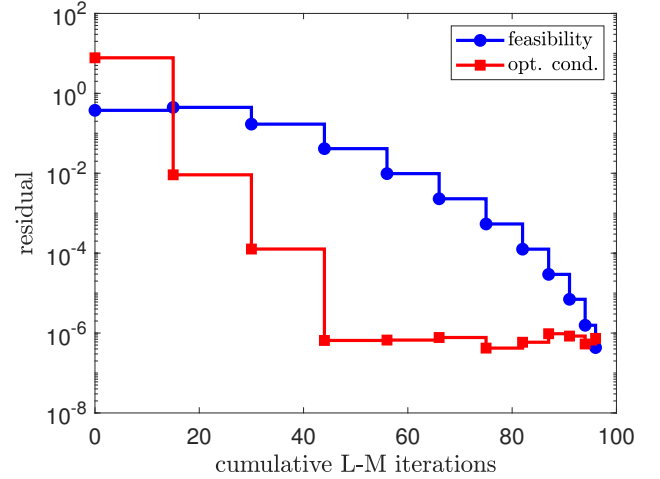
$$\begin{aligned} 2[Df(x)]^T f(x) + [Dg(x)]^T z &= 0, \\ g(x) &= 0. \end{aligned}$$

Zdefiniujmy, odpowiednio, residuum warunku optymalności (ang. *optimality condition residual*, OR) i residuum warunku dopuszczalności (ang. *feasibility residual*, FR),

$$OR = \|2[Df(x)]^T f(x) + [Dg(x)]^T z\|, \quad (40a)$$

$$FR = \|g(x)\|. \quad (40b)$$

Wraz ze wzrostem liczby iteracji wskaźniki te powinny być coraz mniejsze, w teorii wyrażenia, odpowiednio, $\|2[Df(x)]^T f(x) + [Dg(x)]^T z\|$ i $\|g(x)\|$ powinny dążyć do zera. W Tabeli 1 przedstawiono wartości logarytmów tych wskaźników dla kolejnych iteracji, tzn. dla kolejnych par $(x^{(0)}, z^{(0)})$, $(x^{(1)}, z^{(1)})$, itd., natomiast na Rys. 2 wykresy tych wskaźników w funkcji skumulowanej liczby iteracji LM.



Rysunek 2: Residuum warunku dopuszczalności (ang. *feasibility residual*) i residuum warunku optymalności (ang. *optimality condition residual*) w funkcji skumulowanych iteracji Levenberga-Marquardta, w metodzie ALA. (Przykład 1)

Tabela 1: Wartości residuów dla warunków wykonalności (ang. *feasibility residual*, FR) i optymalności (ang. *optimality condition residual*, OR).

k	$\log_{10}(FR)$	$\log_{10}(OR)$
0	-0.4260	0.8892
1	-0.3515	-2.0393
2	-0.7710	-3.8973
3	-1.3848	-6.1855
4	-2.0100	-6.1758
5	-2.6393	-6.1117
6	-3.2697	-6.3768
7	-3.9004	-6.2303
8	-4.5313	-6.0172
9	-5.1553	-6.0757
10	-5.8058	-6.2736

2 Zadania

Zadanie 1. Powtórzyć obliczenia z przykładu 1 i wykonać odpowiednie wykresy (Rys. 1). Wyznaczyć wartości wskaźników FR i OR dla kolejnych iteracji.

Zadanie 2. Wykonać ćwiczenie 19.1 z [1]. (Rozwiązanie $x^* = [0.5677 \ 0.8328 \ 0.5753]$).

Zadanie 3. Wykonać ćwiczenie 19.3 z [1]

[1] S. Boyd and L. Vandenberghe. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018.

[2] A. R. Conn, N. I. M. Gould, and P. L. Toint. A globally convergent augmented lagrangian algorithm for optimization with general constraints and simple bounds. *SIAM journal on numerical analysis*, 28(2):545–572, 1991.

19.1 *Projection on a curve.* We consider a constrained nonlinear least squares problem with three variables $x = (x_1, x_2, x_3)$ and two equations:

$$\begin{aligned} &\text{minimize} && (x_1 - 1)^2 + (x_2 - 1)^2 + (x_3 - 1)^2 \\ &\text{subject to} && x_1^2 + 0.5x_2^2 + x_3^2 - 1 = 0 \\ &&& 0.8x_1^2 + 2.5x_2^2 + x_3^2 + 2x_1x_3 - x_1 - x_2 - x_3 - 1 = 0. \end{aligned}$$

The solution is the point closest to $(1, 1, 1)$ on the nonlinear curve defined by the two equations.

- (a) Solve the problem using the augmented Lagrangian method. You can start the algorithm at $x^{(1)} = 0$, $z^{(1)} = 0$, $\mu^{(1)} = 1$, and start each run of the Levenberg–Marquardt method with $\lambda^{(1)} = 1$. Stop the augmented Lagrangian method when the feasibility residual $\|g(x^{(k)})\|$ and the optimality condition residual

$$\|2Df(x^{(k)})^T f(x^{(k)}) + Dg(x^{(k)})^T z^{(k)}\|$$

are less than 10^{-5} . Make a plot of the two residuals and of the penalty parameter μ versus the cumulative number of Levenberg–Marquardt iterations.

- (b) Solve the problem using the penalty method, started at $x^{(1)} = 0$ and $\mu^{(1)} = 1$, and with the same stopping condition. Compare the convergence and the value of the penalty parameter with the results for the augmented Lagrangian method in part (a).

Rysunek 3: Ćwiczenie 19.1 z [1]

19.3 *Boolean least squares.* The *Boolean least squares problem* is a special case of the constrained nonlinear least squares problem (19.1), with the form

$$\begin{aligned} &\text{minimize} && \|Ax - b\|^2 \\ &\text{subject to} && x_i^2 = 1, \quad i = 1, \dots, n, \end{aligned}$$

where the n -vector x is the variable to be chosen, and the $m \times n$ matrix A and the m -vector b are the (given) problem data. The constraints require that each entry of x is either -1 or $+1$, *i.e.*, x is a Boolean vector. Since each entry can take one of two values, there are 2^n feasible values for the vector x . The Boolean least squares problem arises in many applications.

One simple method for solving the Boolean least squares problem, sometimes called the *brute force method*, is to evaluate the objective function $\|Ax - b\|^2$ for each of the 2^n possible values, and choose one that has the least value. This method is not practical for n larger than 30 or so. There are many heuristic methods that are much faster to carry out than the brute force method, and approximately solve it, *i.e.*, find an x for which the objective is small, if not the smallest possible value over all 2^n feasible values of x . One such heuristic is the augmented Lagrangian algorithm 19.2.

- (a) Work out the details of the update step in the Levenberg–Marquardt algorithm used in each iteration of the augmented Lagrangian algorithm, for the Boolean least squares problem.
- (b) Implement the augmented Lagrangian algorithm for the Boolean least squares problem. You can choose the starting point $x^{(1)}$ as the minimizer of $\|Ax - b\|^2$. At each iteration, you can obtain a feasible point $\tilde{x}^{(k)}$ by rounding the entries of $x^{(k)}$ to the values ± 1 , *i.e.*, $\tilde{x}^{(k)} = \text{sign}(x^{(k)})$. You should evaluate and plot the objective value of these feasible points, *i.e.*, $\|A\tilde{x}^{(k)} - b\|^2$. Your implementation can return the best rounded value found during the iterations. Try your method on some small problems, with $n = m = 10$ (say), for which you can find the actual solution by the brute force method. Try it on much larger problems, with $n = m = 500$ (say), for which the brute force method is not practical.

Rysunek 4: Ćwiczenie 19.3 z [1]